

0. Возникшие и допущения

S - сторона входного изображения, B - размер батча, для слоя l : $(\text{line}), (\text{and})$ - число эн-ов входа и выхода (с учетом батча), m_l - число параметров;

$$1 \text{ MAC} = 2 \text{ FLOPs};$$

FP32 - 4 байта на элемент;

не учитывается формула CuDNN ;

l - номер слоя, $l = 0 \dots 17$; K - число запусков CUDA-ядер за forward (Batch не учитывается); C_l - каналы выхода l ;

$n_l = C_l K_l M_l = C_l S_l^2$, $n_0 = 3S^2$; C_{in} , C_{out} - вх. и вых. каналы Conv;

F_{in} , F_{out} - вх. и вых. параметры Linear; d - коэффициент масштабирования: $(\frac{S}{d})^2$.

F_l - FLOPs слоя l [FLOP]; M_l - память слоя l [байт]; $|W_l|$ - число параметров слоя l [эл.]; t_l - время работы ядра слоя l ;

1. FLOPs

$$F_{conv} = 2 C_{in} C_{out} k^2 \cdot S_{out} \cdot B$$

$$F_{linear} = 2 B F_{in} F_{out} + B F_{out}$$

$$F_{relu} = B C S^2$$

$$F_{maxpool} = (k^2 - 1) \cdot B C S_{out}^2$$

$$F_{avgpool} = B C S_{in}^2$$

$$F_{flatten} = 0,$$

где C_{in} - входные каналы, C_{out} - выходные каналы, k - размер ядра, S_{out} - выходное разрешение, B - размер батча, F_{in} , F_{out} - входные и выходные параметры, S - размер батча

$$Conv 4 \times 4 3 \rightarrow 32, d=2 \quad 2 \cdot 3 \cdot 32 \cdot 119/4 S^2 = 2352 S^2$$

$$Conv 5 \times 5 32 \rightarrow 64, d=4 \quad 2 \cdot 32 \cdot 64 \cdot 25/16 S^2 = 6400 S^2$$

$$Conv 3 \times 3 64 \rightarrow 128, d=8 \quad 2 \cdot 64 \cdot 128 \cdot 9/64 S^2 = 2304 S^2$$

$$Conv 1 \times 1 128 \rightarrow 256, d=8 \quad 2 \cdot 128 \cdot 256 \cdot 1/64 S^2 = 1024 S^2$$

$$Conv 3 \times 3 256 \rightarrow 256, d=16 \quad 2 \cdot 256 \cdot 256 \cdot 9/256 S^2 = 4608 S^2$$

$$Conv 1 \times 1 256 \rightarrow 512, d=16 \quad 2 \cdot 256 \cdot 512 \cdot 1/256 S^2 = 1024 S^2$$

$$\sum_{conv} = 14412 S^2$$

$$\sum_{relu} = (8 + 4 + 2 + 4 + 1 + 2) S^2 + 256 = 21 S^2 + 256$$

$$F_{maxpool} = (9 - 1) \cdot 2 S^2 = 16 S^2$$

$$F_{avgpool} = 512 \cdot \left(\frac{S}{16}\right)^2 = 2 S^2$$

$$F_{linear} = 256 \cdot (2 \cdot 512 + 1) + 100 \cdot (2 \cdot 256 + 1) = 313400$$

$$F(S, B) = B \cdot (14412 S^2 + 21 S^2 + 256 + 16 S^2 + 2 S^2 + 313400) =$$

$$= B \cdot (14431 S^2 + 313956)$$

2. Меморгу

Пусть n_l - число элементов выхода слоя l на один образ,
 $n_0 = 38^2$ - вход сети. Тогда n_{l-1} - вход слоя l .

В промежуточной сети в момент работы слоя l активны:

- используемый вход n_0 размера n_0
- вход слоя n_{l-1}
- выход n_l

Relu и Flatten нового тензора не создают.

Меморгу $(S, B) = 4(\max(n_0 + n_{l-1} + n_l) \cdot B + \sum_i |w_i|)$, где
 $\max(n_0 + n_{l-1} + n_l)$ - макс. число активированных данных средислов;
 $\sum_i |w_i|$ - сумма весов модели.

подставим,

$$L_0: \text{Conv } 7 \times 7, 38^2 + 88^2 = 118^2$$

$$L_1: \text{ReLU}, 38^2 + 88^2 = 118^2$$

$$L_2: \text{Max Pool}, 38^2 + 88^2 + 28^2 = 135^2 \quad \checkmark$$

$$L_3: \text{Conv } 5 \times 5, 38^2 + 28^2 + 48^2 = 98^2$$

$$L_4: \text{ReLU}, 38^2 + 48^2 = 68^2$$

$$L_5: \text{Conv } 3 \times 3, 38^2 + 48^2 + 28^2 = 98^2$$

$$L_6: \text{ReLU}, 38^2 + 28^2 = 58^2$$

$$L_7: \text{Conv } 1 \times 1, 38^2 + 28^2 + 48^2 = 98^2$$

$$L_8: \text{ReLU}, 48^2 + 35^2 = 118^2$$

$$L_9: \text{Conv } 3 \times 3, 38^2 + 48^2 + 28^2 = 98^2$$

$$L_{10}: \text{ReLU}, 38^2 + 18^2 = 48^2$$

$$L_{11}: \text{Conv } 1 \times 1, 38^2 + 18^2 + 28^2 = 68^2$$

$$L_{12}: \text{ReLU}, 38^2 + 28^2 = 58^2$$

$$L_{13}: \text{Global Avg Pool}, 38^2 + 28^2 + 512$$

$$L_{14}: \text{Flatten}, 38^2 + 512$$

$$L_{15}: \text{Linear } 512 \rightarrow 256, 38^2 + 512 + 256$$

$$L_{16}: \text{ReLU}, 38^2 + 256$$

$$L_{17}: \text{Linear } 256 \rightarrow 100, 38^2 + 256 + 100$$

$$\max_l(\cdot) = 135^2, \quad l = 2$$

Веса

$$W_{conv} = C_{in} C_{out} \cdot A^2$$

$$W_{linear} = F_{out}(F_{in+1})$$

$$\sum_i |w_i| = 3 \cdot 32 \cdot 48 + 32 \cdot 64 \cdot 25 + 64 \cdot 128 \cdot 8 + 128 \cdot 256 + 256 \cdot 256 \cdot 8 + 256 \cdot 512 + 512 \cdot 256 + 256 \cdot 256 \cdot 100 + 100 = 1040324$$

$$Memory(S, B) = 4 \cdot 13BS^2 + 4 \cdot 1040324 = 52BS^2 + 4161296 \text{ байт.}$$

Асимптотика: активации превалируют веса при $BS^2 \gg 80025$, т.е. при $B=4, S=160$. Обычно,

$$\max_i (n_0 + n_{in} + n_i) \cdot B \gg \sum_i |w_i|$$

3. Bytes Moved

Для каждого слоя ядро читает вход и веса, и пишет выход.

$$M_i = 4(|in_i| + |out_i| + |w_i|) \text{ [байт]},$$

при этом $M_{last} = 0$, т.к. это view тензора.

$$Bytes(S, B) = 4(\sum_i |in_i| + |out_i| + \sum_i |w_i|),$$

$$\text{где } \sum_i |in_i| + |out_i| = (818^2 + 2148)B$$

$$Bytes(S, B) = 4(818BS^2 + 2148B + 1040324) = 364BS^2 + 8592B + 4161296 \text{ байт.}$$

5. Latency

Ядро слоя в тратит время на запуск, на арифметику и обращения к памяти:

$$t_i = t_0 + i \frac{F_i}{V_c} + \frac{M_i}{V_m}$$

Т.к. сеть последовательная, то:

$$Latency = \sum_{i=1}^K t_i = K t_0 + \frac{1}{V_c} \cdot \sum_i F_i + \frac{1}{V_m} \sum_i M_i,$$

$$Latency(S, B, \Theta) = K t_0 + \frac{F(S, B)}{V_c} + \frac{M(S, B)}{V_m}, \quad \Theta = (t_0, V_c, V_m)$$

Т.е. Θ - гиперпараметры.

Но, время на запуск, арифметику и обращения перекрываются, сред.

$$Latency(S, B, \Theta) = K \cdot t_0 + \sum_i \max\left(\frac{F_i}{V_c}, \frac{M_i}{V_m}\right), \quad \Theta = (t_0, V_c, V_m), K=14$$

6. Energy

Энергия состоит из базового потребления энергии, энергии на арифметику и обращение к ДРАМ на каждом слое.

$$E_c = P_{idle} t_c + e_{flor} F_c + e_{byte} M_c$$

$$Energy(S, B, \Theta) = P_{idle} \cdot Latency(S, B, \Theta) + e_{flor} \cdot F(S, B) + e_{byte} M(S, B),$$

$$\Theta = (P_{idle}, e_{flor}, e_{byte}).$$